
**ANALYSE DE LA ROBUSTESSE
DES MOTS DE PASSE AVEC
L'ENTROPIE DE SHANNON**

*Étude quantitative et comparative de la sécurité des mots de passe
à l'aide de la théorie de l'information*

RÉALISÉ PAR

JAWAD FADEL Roda

NIVEAU

L3 Mathématiques

UNITÉ D'ENSEIGNEMENT

Théorie de l'information

ENCADRÉ PAR

Bullynck Maarten

ÉTABLISSEMENT

Université Paris 8

Table des matières

1	Introduction	3
2	Théorie de Shannon	3
2.1	Définition de l'entropie	3
2.2	Entropie maximale	3
2.3	Entropie théorique et entropie réelle	4
3	Approche mathématique	4
3.1	Espace de recherche	4
4	Influence des probabilités du français	5
5	Cas 1 : mot simple	6
5.1	Calcul théorique	6
5.2	Interprétation	7
5.3	Temps de cassage	7
6	Cas 2 : ajout de majuscules	8
6.1	Calcul	8
6.2	Interprétation	8
7	Cas 3 : ajout de chiffres	9
7.1	Calcul	9
7.2	Interprétation	9
8	Cas 4 : caractères spéciaux	10
8.1	Calcul	10
8.2	Interprétation	10
9	Cas 5 : combinaison complète	11
9.1	Calcul	11
9.2	Interprétation	11
10	Cas 6 : mot de passe totalement aléatoire	11
10.1	Calcul	11
10.2	Interprétation	12
11	Croissance exponentielle	12
12	Analyse mathématique globale	12

13 Automatisation avec Python	13
13.1 Programme Python	13
14 Conclusion	15

1 Introduction

Aujourd'hui, presque tous les services numériques utilisent des mots de passe afin de protéger les données personnelles des utilisateurs.

Cependant, beaucoup de personnes choisissent encore des mots de passe faibles et prévisibles :

- mots du dictionnaire ;
- dates de naissance ;
- suites simples ;
- informations personnelles.

Pour améliorer la sécurité, les plateformes imposent souvent :

- des majuscules ;
- des chiffres ;
- des caractères spéciaux ;
- une longueur minimale.

La question étudiée dans ce projet est donc :

Ces règles augmentent-elles réellement la sécurité des mots de passe ?

Pour répondre à cette question, nous allons utiliser l'entropie de Shannon, qui permet de mesurer mathématiquement l'imprévisibilité d'une information.

L'objectif sera de comparer :

- l'entropie théorique ;
- l'entropie réelle ;
- l'effet des habitudes humaines ;
- la différence entre mots humains et mots aléatoires.

2 Théorie de Shannon

2.1 Définition de l'entropie

Claude Shannon introduit l'entropie en 1948 dans la théorie de l'information.

L'entropie mesure l'incertitude d'une information :

- une information prévisible possède une faible entropie ;
- une information aléatoire possède une forte entropie.

La formule de Shannon est :

$$H(X) = - \sum_{i=1}^n p_i \log_2(p_i)$$

où :

- p_i représente la probabilité d'apparition d'un caractère ;
- $H(X)$ représente l'entropie en bits.

2.2 Entropie maximale

L'entropie maximale est obtenue lorsque tous les caractères possèdent la même probabilité.

Dans ce cas :

$$H = L \log_2(N)$$

avec :

- L : longueur du mot de passe ;
- N : taille de l'alphabet.

2.3 Entropie théorique et entropie réelle

Dans ce travail, nous distinguerons deux notions d'entropie.

L'entropie théorique est calculée en supposant que tous les caractères de l'alphabet sont équiprobables et indépendants.

Dans ce cas, la formule devient :

$$H = L \log_2(N)$$

où :

- L est la longueur du mot de passe ;
- N est la taille de l'alphabet utilisé.

Cette hypothèse correspond à un mot de passe totalement aléatoire.

Cependant, les mots de passe réels ne sont généralement pas produits de manière uniforme. Les utilisateurs privilégient certains caractères, certains mots et certaines structures linguistiques.

Nous appellerons alors entropie réelle l'entropie calculée à partir de la fréquence effective des caractères observés dans le mot de passe.

Cette entropie est donnée par la formule de Shannon :

$$H(X) = - \sum_{i=1}^n p_i \log_2(p_i)$$

où p_i représente la fréquence observée du caractère i .

L'entropie réelle est donc généralement inférieure à l'entropie théorique car les caractères n'apparaissent pas tous avec la même probabilité.

L'objectif de cette étude est précisément de comparer ces deux approches afin de mesurer l'influence des habitudes humaines sur la robustesse des mots de passe.

3 Approche mathématique

3.1 Espace de recherche

Le nombre total de mots de passe possibles est :

$$\Omega = N^L$$

Ce nombre représente l'espace de recherche qu'un attaquant doit parcourir.

L'entropie correspond alors au logarithme binaire de cet espace :

$$H = \log_2(\Omega)$$

Comme :

$$\Omega = N^L$$

on obtient :

$$H = \log_2(N^L)$$

Puis :

$$H = L \log_2(N)$$

Cette formule montre que :

- l'entropie augmente linéairement avec la longueur ;
- l'espace de recherche augmente exponentiellement.

4 Influence des probabilités du français

Les calculs précédents supposent que toutes les lettres apparaissent avec la même probabilité.

Or, dans la langue française, certaines lettres sont beaucoup plus fréquentes que d'autres.

Par exemple :

Lettre	Fréquence approximative
E	14.7 %
A	7.6 %
S	7.9 %
I	7.5 %
N	7.2 %
Z	0.1 %
W	0.1 %
K	0.05 %

Les probabilités ne sont donc pas uniformes.

L'entropie moyenne d'une lettre française peut être estimée par :

$$H = - \sum_{i=1}^{26} p_i \log_2(p_i)$$

où les probabilités p_i sont les fréquences réelles des lettres du français.

Les estimations classiques donnent une entropie comprise entre :

4 et 4.2 bits par lettre

alors que l'entropie maximale uniforme vaut :

$$\log_2(26) \approx 4.70$$

bits par lettre.

On constate donc une perte d'environ :

$$4.70 - 4.10 \approx 0.60$$

bit par caractère.

Pour un mot de passe de longueur 17 constitué uniquement de lettres françaises :

$$17 \times 4.70 = 79.9$$

bits dans le modèle uniforme,
contre environ :

$$17 \times 4.10 = 69.7$$

bits lorsqu'on utilise les fréquences réelles de la langue.

Cette différence montre que l'utilisation de mots issus du langage naturel réduit significativement l'incertitude et facilite les attaques basées sur les dictionnaires.

Remarque : dans les exemples étudiés par la suite, les valeurs d'entropie réelle indiquées sont des estimations destinées à illustrer l'influence des habitudes humaines sur la sécurité des mots de passe. Elles ne constituent pas des mesures exactes obtenues à partir d'une base de données de mots de passe réels.

Ces valeurs doivent être interprétées comme des ordres de grandeur permettant de comparer les différents mots de passe étudiés. Elles visent à mettre en évidence l'écart entre l'entropie théorique et la sécurité réellement observée lorsque les utilisateurs adoptent des habitudes prévisibles.

5 Cas 1 : mot simple

Considérons le mot de passe :

`bonjourjesuisici`

5.1 Calcul théorique

Longueur :

$$L = 17$$

Alphabet :

$$N = 26$$

Nombre total de possibilités :

$$\Omega = 26^{17}$$

$$\Omega \approx 4.36 \times 10^{24}$$

Entropie :

$$H = 17 \log_2(26)$$

Or :

$$\log_2(26) \approx 4.70044$$

Donc :

$$H \approx 17 \times 4.70044$$

$$H \approx 79.91 \text{ bits}$$

5.2 Interprétation

Cette valeur signifie que le mot de passe possède théoriquement :

$$2^{79.91}$$

configurations possibles.

Cela semble extrêmement sécurisé.

Cependant, ce calcul suppose :

- des caractères aléatoires ;
- des probabilités uniformes ;
- aucune structure linguistique.

Or ce mot de passe contient :

- des mots français connus ;
- des lettres fréquentes ;
- des structures prévisibles.

Les attaques modernes utilisent des dictionnaires contenant des millions de mots courants.

Ainsi, l'entropie réelle est beaucoup plus faible :

$$H_{\text{réelle}} \approx 25 \text{ bits}$$

5.3 Temps de cassage

Supposons une machine capable de tester :

$$10^9$$

mots de passe par seconde.

Temps moyen :

$$T = \frac{\Omega}{2 \times 10^9}$$

$$T \approx 2.18 \times 10^{15} \text{ secondes}$$

Conversion en années :

$$1 \text{ année} \approx 3.15 \times 10^7 \text{ secondes}$$

Donc :

$$T \approx 6.9 \times 10^7 \text{ années}$$

Ce résultat est trompeur car il suppose un mot de passe totalement aléatoire.

6 Cas 2 : ajout de majuscules

Mot de passe :

BonjourJeSuisIci

6.1 Calcul

Alphabet :

$$N = 52$$

Entropie :

$$H = 17 \log_2(52)$$

Or :

$$\log_2(52) \approx 5.70044$$

Donc :

$$H \approx 96.91 \text{ bits}$$

Gain théorique :

$$\Delta H = 96.91 - 79.91$$

$$\Delta H \approx 17 \text{ bits}$$

6.2 Interprétation

Le passage de 26 à 52 caractères double la taille de l'alphabet :

$$52 = 2 \times 26$$

Or :

$$\log_2(52) = \log_2(2 \times 26)$$

$$= 1 + \log_2(26)$$

Chaque caractère gagne donc environ :

$$1 \text{ bit}$$

Mathématiquement, les majuscules augmentent fortement le nombre de possibilités. Cependant, les utilisateurs placent souvent les majuscules :

- au début du mot ;
- au début de chaque syllabe ;
- selon des habitudes connues.

Les logiciels de cassage exploitent ces comportements.
Ainsi, l'entropie réelle augmente peu :

$$H_{\text{réelle}} \approx 30 \text{ bits}$$

7 Cas 3 : ajout de chiffres

Mot de passe :

Bonjour2025Ici

7.1 Calcul

Alphabet :

$$N = 62$$

Longueur :

$$L = 16$$

Entropie :

$$H = 16 \log_2(62)$$

Or :

$$\log_2(62) \approx 5.954$$

Donc :

$$H \approx 95.26 \text{ bits}$$

7.2 Interprétation

L'ajout des chiffres augmente fortement le nombre de possibilités :

$$62^{16}$$

Ce nombre est gigantesque.

Cependant, les humains utilisent souvent :

- des années ;
- des dates ;
- des suites numériques simples.

Par exemple :

2024, 2025, 1234

Les logiciels de cassage testent ces possibilités en priorité.
L'entropie réelle reste donc relativement faible :

$$H_{\text{réelle}} \approx 35 \text{ bits}$$

8 Cas 4 : caractères spéciaux

Mot de passe :

Bonjour!2025?

8.1 Calcul

Alphabet :

$$N = 82$$

Longueur :

$$L = 14$$

Entropie :

$$H = 14 \log_2(82)$$

Or :

$$\log_2(82) \approx 6.357$$

Donc :

$$H \approx 89 \text{ bits}$$

8.2 Interprétation

Les caractères spéciaux augmentent encore la taille de l'alphabet.

Le nombre total de possibilités devient immense.

Cependant, les utilisateurs choisissent souvent :

- les mêmes symboles ;
- des positions prévisibles ;
- des caractères simples.

Exemples fréquents :

!, ?, @, #

Les attaques modernes utilisent des modèles probabilistes qui réduisent énormément l'espace de recherche réel.

L'entropie réelle reste donc limitée :

$$H_{\text{réelle}} \approx 40 \text{ bits}$$

9 Cas 5 : combinaison complète

Mot de passe :

B0nj0ur!2025#

9.1 Calcul

Alphabet :

$$N = 82$$

Longueur :

$$L = 14$$

Entropie :

$$H = 14 \log_2(82)$$

$$H \approx 89 \text{ bits}$$

9.2 Interprétation

Le mot de passe semble très complexe visuellement.

Cependant, les substitutions classiques sont bien connues :

- o $\rightarrow$ 0 ;
- a $\rightarrow$ @ ;
- e $\rightarrow$ 3.

Les logiciels de cassage testent automatiquement ces variantes.

Ainsi, la complexité visuelle ne correspond pas forcément à une forte sécurité réelle.

Entropie réelle :

$$H_{\text{réelle}} \approx 45 \text{ bits}$$

10 Cas 6 : mot de passe totalement aléatoire

Mot de passe :

fK9#pL2@xQ7!mT4\$

10.1 Calcul

Alphabet :

$$N = 82$$

Longueur :

$$L = 16$$

Entropie :

$$H = 16 \log_2(82)$$

$$H \approx 101.8 \text{ bits}$$

10.2 Interprétation

Dans ce cas :

- les caractères sont choisis aléatoirement ;
- les probabilités sont presque uniformes ;
- il n'existe aucun motif linguistique.

Les hypothèses du modèle mathématique deviennent donc presque exactes.

L'entropie réelle devient très proche de l'entropie théorique :

$$H_{\text{réelle}} \approx 100 \text{ bits}$$

Ce type de mot de passe est beaucoup plus résistant aux attaques.

11 Croissance exponentielle

Le nombre de possibilités augmente exponentiellement avec la longueur.

Par exemple :

$$26^5 = 11881376$$

mais :

$$26^{10} = 141167095653376$$

et :

$$26^{20} \approx 2 \times 10^{28}$$

Ainsi, quelques caractères supplémentaires augmentent énormément la difficulté du cassage.

12 Analyse mathématique globale

L'entropie croît linéairement avec la longueur :

$$H = L \log_2(N)$$

Avec un alphabet de 82 caractères :

$$\log_2(82) \approx 6.36$$

Chaque caractère supplémentaire ajoute donc environ :

$$6.36 \text{ bits}$$

Ajouter un seul caractère multiplie le nombre de possibilités par :

$$82$$

Ajouter deux caractères multiplie l'espace de recherche par :

$$82^2 = 6724$$

Cela montre que la longueur d'un mot de passe est souvent plus importante que sa simple complexité visuelle.

13 Automatisation avec Python

Afin d'automatiser les calculs, nous avons développé un programme Python.

Ce programme :

- calcule l'entropie de Shannon ;
- calcule l'entropie théorique ;
- calcule le nombre de possibilités ;
- estime le temps de cassage.

Le programme suivant calcule l'entropie réelle d'un mot de passe à partir des fréquences observées de ses caractères.

Il ne tient pas compte des probabilités de la langue française ni des dépendances entre lettres. Il fournit donc une estimation simplifiée de l'entropie réelle fondée uniquement sur la distribution des caractères présents dans le mot de passe étudié.

13.1 Programme Python

```
from collections import Counter
from math import log2

# Fonction qui calcule l'entropie de Shannon
def entropie_shannon(mot_de_passe):

    # Compte le nombre d'apparitions
    # de chaque caractere
    occurrences = Counter(mot_de_passe)

    # Longueur du mot de passe
    longueur = len(mot_de_passe)

    # Variable contenant l'entropie
    entropie = 0

    # Parcours des occurrences
    for nombre in occurrences.values():

        # Calcul de la probabilite
        probabilite = nombre / longueur
```

```

        # Application de la formule
        # de Shannon
        entropie -= probabilite * log2(probabilite)

    # Retour de l'entropie totale
    return entropie * longueur

# Fonction qui calcule
# l'entropie theorique
def entropie_theorique(longueur,
                       taille_alphabet):

    return longueur * log2(taille_alphabet)

# Fonction qui calcule
# le nombre total de possibilites
def nombre_possibilites(longueur,
                       taille_alphabet):

    return taille_alphabet ** longueur

# Demande du mot de passe
mot_de_passe = input("Mot de passe : ")

# Calcul de la longueur
longueur = len(mot_de_passe)

# Demande de la taille
# de l'alphabet
taille_alphabet = int(
    input("Taille de l'alphabet : ")
)

print()

# Affichage de l'entropie theorique
print(
    "Entropie theorique :",
    entropie_theorique(
        longueur,
        taille_alphabet
    ),
    "bits"
)

# Affichage de l'entropie de Shannon

```

```

print(
    "Entropie de Shannon :",
    entropie_shannon(mot_de_passe),
    "bits"
)

# Affichage du nombre de possibilites
print(
    "Nombre de possibilites :",
    nombre_possibilites(
        longueur,
        taille_alphabet
    )
)

```

14 Conclusion

Cette étude a permis d'analyser mathématiquement la robustesse des mots de passe à l'aide de l'entropie de Shannon.

Dans un premier temps, nous avons étudié l'entropie théorique, qui suppose :

- des caractères choisis aléatoirement ;
- des probabilités uniformes ;
- une indépendance entre les caractères.

Grâce à cette approche, nous avons pu calculer :

- le nombre total de possibilités ;
- l'espace de recherche ;
- le temps théorique nécessaire à une attaque par force brute.

Les calculs montrent que l'espace des mots de passe augmente extrêmement rapidement avec :

- la longueur du mot de passe ;
- la taille de l'alphabet utilisé.

En effet, le nombre de possibilités suit une croissance exponentielle :

$$\Omega = N^L$$

Ainsi, l'ajout de quelques caractères peut multiplier considérablement le nombre total de combinaisons possibles.

Cependant, cette étude a également montré les limites importantes de l'entropie théorique.

Dans la pratique, les utilisateurs ne choisissent pas leurs mots de passe de manière aléatoire. Ils utilisent souvent :

- des mots du dictionnaire ;
- des dates ;
- des suites numériques ;
- des substitutions connues ;
- des caractères spéciaux placés à des positions prévisibles.

Ces habitudes rendent les mots de passe beaucoup plus faciles à deviner que ce que prédit le modèle mathématique idéal.

Nous avons ainsi observé une différence importante entre :

- l'entropie théorique ;
- l'entropie réelle.

Les résultats obtenus montrent que :

- les mots de passe basés sur le langage naturel restent relativement faibles ;
- l'ajout de majuscules, chiffres et symboles améliore partiellement la sécurité ;
- la complexité visuelle ne garantit pas une forte robustesse ;
- les mots de passe totalement aléatoires restent les plus sécurisés.

Cette étude met également en évidence l'importance de la longueur du mot de passe. En effet, augmenter la longueur possède souvent un effet plus important que simplement ajouter quelques symboles ou majuscules.

L'automatisation en Python a permis de vérifier expérimentalement les calculs théoriques et de mieux comprendre le fonctionnement de l'entropie de Shannon appliquée aux mots de passe.

Enfin, ce projet montre que l'entropie de Shannon constitue un outil mathématique très utile pour comparer différents mots de passe, mais qu'elle ne suffit pas à elle seule pour mesurer parfaitement la sécurité réelle.

Les méthodes modernes d'attaque utilisent aujourd'hui :

- des modèles probabilistes ;
- des dictionnaires massifs ;
- des chaînes de Markov ;
- l'intelligence artificielle.

L'étude de la sécurité des mots de passe nécessite donc à la fois :

- des outils mathématiques ;
- une analyse statistique ;
- une compréhension du comportement humain.

Pour prolonger ce travail, il serait possible :

- d'utiliser de véritables bases de mots de passe compromis ;
- d'étudier les attaques modernes utilisées en cybersécurité ;
- de comparer plusieurs méthodes de mesure de robustesse ;
- d'utiliser des modèles probabilistes plus avancés.

Ce projet montre ainsi le lien important entre :

- mathématiques ;
- informatique ;
- probabilités ;
- cybersécurité.

Bibliographie

1. Claude E. Shannon, *A Mathematical Theory of Communication*, Bell System Technical Journal, 1948.
2. Wikipédia, *Fréquence des lettres*.
[https://fr.wikipedia.org/wiki/FrÃquence_des_lettres](https://fr.wikipedia.org/wiki/Fr%C3%A9quence_des_lettres)
3. Wikipédia, *Entropie de Shannon*.
https://fr.wikipedia.org/wiki/Entropie_de_Shannon
4. Wikipédia, *Théorie de l'information*.
[https://fr.wikipedia.org/wiki/ThÃorie_de_l_information](https://fr.wikipedia.org/wiki/Th%C3%A9orie_de_l_information)

5. M. Gaines, *Cryptographie et fréquences des lettres*.
<https://www.cipherchallenge.org/wp-content/uploads/2022/09/gaines.pdf>
6. Malik et al., *Password Strength and Entropy Analysis*.
https://www.cs.umd.edu/sites/default/files/scholarly_papers/Malik.pdf
7. ANSSI, *Recommandations relatives aux mots de passe*.
<https://www.ssi.gouv.fr>